

Rúbrica de evaluación

- Resumen: 0.2/0.2
- Introducción: 0.2/0.2
- Planteamiento del problema: 0.5/0.5
- Antecedentes: 0.3/0.3
- Justificación: 0.5/0.5
- Hipótesis/Objetivos: 0.1/0.1
- Metodología: 1.0/1.0
- Análisis de resultados: 0.7/0.7
- Conclusiones: 0.7/0.7
- Discusión/Trabajos futuros: 0.3/0.3
- Redacción: 0.5/0.5

Clasificación de Fibrilación Auricular a partir de la derivación corta de un electrocardiograma

Nota: 5.0

Bravo Santacruz Juan Sebastian, Ingeniería Electrónica, Javeriana. Lavao Osorio Sergio
Ingeniería Electrónica, Javeriana. Zambrano Acosta Daniel Stiven, Ingeniería Electrónica,
Javeriana.

Hay varios aspectos por mejorar para la publicación del trabajo. Si desean hacerlo (aprovechando vacaciones), hágnmelo saber y nos reunimos.

I. RESUMEN.

La detección de fibrilación auricular a partir de una sola derivación con el uso de algoritmos referentes a inteligencia artificial, tienen algunas dificultades en cuanto a su fiabilidad, es por ello que en este documento se compara el desempeño de dos clasificadores no lineales para clasificar electrocardiogramas en ritmo sinusal normal y fibrilación auricular. Lo anterior se entrenó y probó usando la base de datos de *PhysioNet*, de la cual se extrajeron cuatro características, la covarianza y desviación estándar del intervalo RR, la diferencia entre los cinco mayores tiempos y los cinco menores del intervalo RR y la relación entre el número de ondas P y el número de ondas R. Una vez entrenados los algoritmos se calcularon las métricas de rendimiento, que dieron a las redes neuronales profundas el mejor puntaje, con un Accuracy de 76.6233 %, una especificidad de 82.822% y una sensibilidad de 69.6551, lo que hace alusión a que el algoritmo es más fiable detectando fibrilación auricular que un ritmo sinusal normal.

II. INTRODUCCIÓN.

En este trabajo se introducen las principales características para el análisis de señales un electrocardiograma (ECG) de una derivación y de corta duración con la finalidad de detectar automáticamente un tipo de arritmia, la fibrilación auricular.

La esencia del reto es clasificar una condición cardíaca, para esto es pertinente caracterizar dicha condición realizando un planteamiento del problema adecuado, así como explayar los antecedentes y estado del arte para soportar una justificación respaldada por una hipótesis veraz. Luego de una apropiada caracterización del reto se presentará la metodología pensada e implementada la cual tiene como núcleo fundamental el uso de algoritmos de inteligencia artificial que estén en la capacidad de generar técnicas automáticas de detección de fibrilación auricular basadas en un número relativamente pequeño de características extraídas de una señal de ECG de una derivación y de corta duración, y en la aplicación de técnicas de aprendizaje autónomo. Para finalmente extraer resultados y realizar su respectivo análisis comparando su precisión, especificidad y sensibilidad de los clasificadores con el fin de completar el artículo con las conclusiones que se encontraron más relevantes y decisivas.

III. PLANTEAMIENTO DEL PROBLEMA

La Fibrilación Auricular (FA) es una condición cardíaca, muchas veces asintomática, la cual se presenta en episodios persistentes u ocasionales en los cuales se tiene un ritmo cardíaco irregular (arritmia cardíaca), esta condición aumenta el riesgo de sufrir ataques cerebrovasculares (ACV o derrame cerebral), coágulos en el corazón, insuficiencia cardíaca, y múltiples complicaciones relacionadas al corazón [1].

En la mayoría de los casos se obtienen electrocardiogramas con cantidades de ruido importantes debido al número de derivaciones, lo cual hace que los métodos actuales sean susceptibles a diagnósticos erróneos, es por ello por lo que se implementará un algoritmo de clasificación mediante inteligencia artificial, donde se filtre el ruido de las señales y se obtenga mejores resultados.

IV. ANTECEDENTES

La clasificación y detección de una FA tiene una alta complejidad debido a que carece de periodicidad, por ello gran parte de los detectores se basan en: estrategias enfocadas en el análisis la actividad auricular o la respuesta de los ventrículos. Para el método de la actividad auricular se tiene presente el análisis de la ausencia de ondas P, para este proceso existe un algoritmo desarrollado en base a la cancelación de QRST durante la fibrilación auricular de un electrocardiograma con dos o más derivaciones. Este método se basa en Echo State Neural Network que estima la función de transferencia no lineal y variante en el tiempo, teniendo en cuenta que la salida es una derivación con actividad auricular y otra sin ella, todo esto para cancelar la actividad ventricular. Esta Red, únicamente actualiza los pesos de la capa de salida cada vez que se procesa una señal. El rendimiento de esta Red se determina con el error cuadrático entre una señal F simulada y la real, según este error el algoritmo es preciso en la estimación de la frecuencia FA dominante para todas las amplitudes de ondas f en contraste a las estimaciones FA basadas en ABS [2].

Siguiendo las lineaciones del reto, en especial la clasificación entre un FA y los ritmos normales del corazón en un electrocardiograma es importante reconocer el trabajo realizado para detectar la transición entre FA y un ritmo sinusal basado en los intervalos RR. Para ello se obtiene la curva de diferencia de distribución para el intervalo RR del histograma de densidad

de estos intervalos, posteriormente se detectaron los picos, los cuales representan cuando se presenta un evento de FA. Una vez identificados estos picos se analizó la desviación estándar y se realizó una prueba de Kolmogorov-Smirnov, para determinar el límite de FA. Con ello se logró obtener una sensibilidad de 96.1% y especificidad de 98.1% con base a datos recolectados de un Holter de 24 horas [3].

Por otro lado, en 2013 aparece un método de clasificación de AF en tiempo real basado en el análisis del número promedio de ondas f . Este método rompe con la tendencia de métodos de detección que solo utilizan el intervalo RR (intervalo comprendido entre onda R de 2 complejos consecutivos) como un parámetro crítico para la detección de FA ya que es común que estos métodos confundan FA con otras arritmias cardíacas [4].

Siguiendo el siguiente diagrama del algoritmo propuesto:

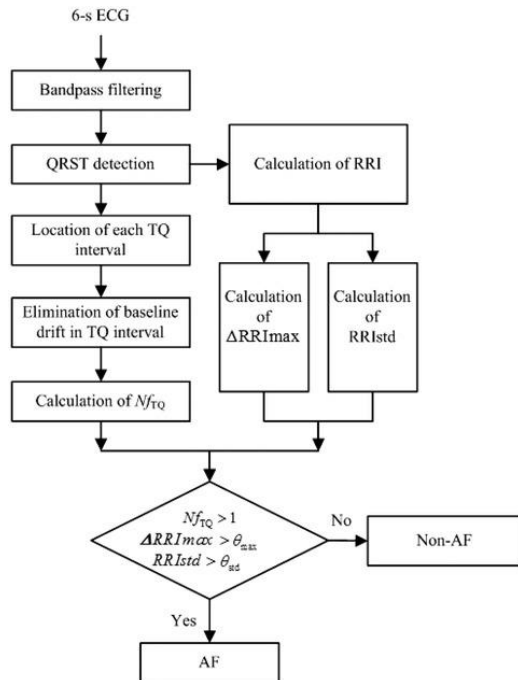


Figura 1. Algoritmo de clasificación basado el número promedio de ondas f [4].

Y utilizando el número promedio de ondas f en un intervalo QT (intervalo comprendido entre pico de onda Q y final de onda T del mismo complejo) Se tomaron tres distintos tipos de datos clínicos de ECG, estos incluían clasificaciones desde normal, FA hasta arritmia no FA. Los resultados obtenidos luego de realizar distintas pruebas mostraron que el método propuesto tenía la capacidad de distinguir FA de un electrocardiograma normal con una Accuracy y una sensibilidad del 93.67% y 94.13% respectivamente. Adicionalmente tuvo una Accuracy del 94.62% y una sensibilidad del 94.13% en las pruebas de distinción entre arritmias no FA y FA; porcentajes considerablemente mejores que otros métodos propuestos [4].

Dentro de las causas de la inapropiada identificación de fibrilación auricular en monitores cardíacos subcutáneos se encuentran las contracciones auriculares prematuras y síndrome

del seno enfermo. En 2014, un grupo implementó una mejora al algoritmo original basado en las diferencias de patrones en intervalos RR durante periodos de 2 minutos. Este nuevo algoritmo reduce la evidencia para detección de FA si hay presencia de ondas P [5].

Para la validación del algoritmo se utilizó datos provenientes de Holters que contenían 2 derivaciones de superficie de electrocardiograma y datos provenientes de monitores cardíacos subcutáneos durante un periodo de 46 horas. Las detecciones de los monitores fueron comparadas con las anotaciones provenientes del Holter para computar el rendimiento de las detecciones [5].

Dentro de los resultados, se obtuvo que el algoritmo mejorado redujo la detección de episodios y duración de FA inapropiadas en un 46% y un 55% respectivamente a la vez que redujo los episodios apropiados en un 2% y la duración apropiada en un 0.1%. Esto da a entender que la incorporación de información sobre ondas P al algoritmo de monitores subcutáneos ayuda a reducir la detección incorrecta de episodios y duración de FA [5].

Por último, se tiene un sistema el cual detecta episodios de FA en una sola derivación en base a la entropía Wavelet (WE), siguiendo el diagrama de flujo que muestra el paso a paso del algoritmo:

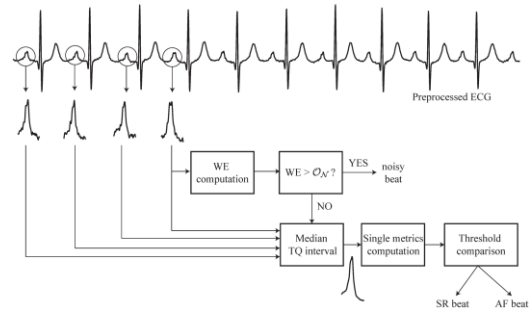


Figura 2. Algoritmo de clasificación basado en WE [6].

Donde el límite óptimo para detectar un latido ruidoso ($WE > O_N$) Este dado por el cálculo de la entropía de Shannon, el cual nos da idea del ruido de la señal [6].




Figura 3. Clasificación de señal ruidosa en función de la WE [6].

En el cual se tuvo como umbral óptimo (O_N) de 1.096.

Este sistema da como resultado una Accuracy del 95%, aunque este es similar a antecedentes, este algoritmo permite una

detección de AF con menos retrasos en tiempo, y alrededor de 5 latidos para su detección, por ende, puede detectar episodios en tiempo real [6].

V. JUSTIFICACIÓN

Con vistas al futuro, y teniendo en cuenta las estimaciones sobre el crecimiento de casos de FA en la población, es necesario implementar métodos de identificación temprana que permitan clasificar la condición del paciente. Con la llegada de nuevas tecnologías en el área de la salud, como lo es el aprendizaje de máquina, es posible desarrollar algoritmos de alta fiabilidad y bajo tiempo de respuesta, los cuales reduzcan la intervención humana a la hora de identificar la condición, disminuyendo así, el tiempo para realizar un diagnóstico.

VI. HIPÓTESIS

¿Cómo es posible clasificar la fibrilación auricular a partir de una derivación corta de un electrocardiograma usando métodos y algoritmos de inteligencia artificial?

VII. OBJETIVO

Clasificar los ritmos cardíacos como sinusal normal y FA a partir de un electrocardiograma de una sola derivación usando un algoritmo clasificador de Inteligencia Artificial.

VIII. METODOLOGÍA

Los datos que se utilizaron fueron recolectados por dispositivos de la empresa Alipcorp, quienes se enfocan en inteligencia artificial en el área de la salud. En esta base de datos se tiene un grupo de entrenamiento que contiene 8528 registros de un ECG de una sola derivación de los cuales 5154 corresponden a ritmo sinusal normal, 771 a FA, 2557 a otro tipo de arritmia y 46 a muy ruidoso para clasificar [7]. Para este caso, se utilizaron únicamente los datos de ritmo sinusal normal y AF y se realizará el balance de estas clases.

Todos los registros de esta base de datos fueron muestreados a 300Hz y filtrados con un filtro pasa banda, para finalmente proporcionar un formato compatible con MATLAB V4 que será leído para extraer los datos. [7]

Para la solución de la problemática se hizo uso de Python y de librerías enfocadas al aprendizaje de maquina (Sklearn, etc.), para el cálculo y ejecución del algoritmo a implementar se harán pruebas sobre un computador con las siguientes características:

Core i7 6700 8 Núcleos a 3.7GHz, 16GB RAM, Nvidia GTX 1080 8GB.

A nivel de software, el lenguaje de programación y las librerías utilizadas son las siguientes: Python 3.9, Sklearn, pandas, keras, numpy, scipy.io, sys.

Inicialmente, se balancearon las clases con base al número de muestras clasificadas como fibrilación auricular. Una vez balanceadas las clases, se realizó la extracción de las características relevantes para la detección de fibrilación

auricular. Para ello inicialmente, se identificaron los complejos QRS encontrando los picos de las ondas R de cada una de las señales. Se utilizó el módulo neurokit2 para la detección de los picos; a través de un filtrado de cada una de las señales que maximiza la energía del complejo QRS y utilizando el algoritmo de Pan Tompkins, se identificaron cada uno de los complejos QRS que componían las señales. [8]

Una vez identificadas las distintas ondas R, se encontraron los tiempos de los intervalos RR. Tomando una ventana de tiempo a la izquierda de cada una de las ondas R, cuya duración es una relación a la duración de los intervalos RR, se encontraron las distintas ondas P. Para esto, se tomó un umbral de 3 veces el valor promedio de toda la señal total.

Con los tiempos de las ondas R y las ondas P, se obtuvieron las distintas características para utilizadas para el entrenamiento de los modelos de clasificación. Teniendo en cuenta que durante la fibrilación auricular se pueden presentar irregularidades en los tiempos de intervalos RR y la ausencia de ondas P, se tomaron como características la desviación estándar de los intervalos RR, la covarianza de los intervalos RR, la relación entre el número de ondas P y ondas R y la diferencia entre el promedio de los 5 intervalos RR más largos y el promedio de los 5 intervalos RR más cortos. [9]

Ya teniendo construida la matriz con las características extraídas, se realizó la segmentación de esta tomando 80% del total de muestras para el conjunto de entrenamiento, 20% para el conjunto de validación y el 20% restante para el conjunto de prueba.

Se realizó el entrenamiento de 6 modelos distintos, 3 DNN y 3 SVM siguiendo las siguientes configuraciones:

| DNN | Estructura (Número de neuronas por capa) | Función de activación | Optimizador |
|-----|--|-----------------------|-------------|
| 1 | 4-8-1 | Sigmoide | Adam |
| 2 | 4-16-8-1 | Sigmoide | Adam |
| 3 | 4-24-16-1 | Sigmoide | Adam |

Tabla 1. Arquitecturas DNN.

| SVM | kernel | Grado | Estrategia |
|-----|--------|-------|------------|
| 1 | Poly | 2 | OVA |
| 2 | Poly | 3 | OVA |
| 3 | Poly | 4 | OVA |

Tabla 2. Configuración SVM.

Para el entrenamiento de los distintos modelos, se hizo uso de validación cruzada 4-fold tomando como métrica de desempeño el binnary accuracy del conjunto de validación. Se seleccionó la arquitectura con mejor rendimiento y se obtuvieron las métricas de rendimiento con el conjunto de prueba.

IX. ANÁLISIS DE RESULTADOS.

Los resultados obtenidos del entrenamiento de cada uno de los modelos presentados anteriormente se presentan en las siguientes tablas:

| Round | Accuracy | | |
|-------|----------|--------|--------|
| | SVM 1 | SVM 2 | SVM 3 |
| 1 | 66.02% | 61.81% | 50.16% |
| 2 | 65.26% | 56.16% | 46.75% |
| 3 | 69.48% | 55.51% | 50.65% |
| 4 | 70.45% | 51.30% | 47.08% |

Tabla 3. Accuracy de SVM.

| Round | Accuracy | | |
|-------|----------|--------|--------|
| | DNN 1 | DNN 2 | DNN 3 |
| 1 | 77.34% | 76.05% | 76.37% |
| 2 | 77.27% | 75.00% | 75.32% |
| 3 | 78.89% | 79.54% | 79.87% |
| 4 | 76.94% | 75.97% | 75.97% |

Tabla 4. Accuracy de DNN.

De los anteriores resultados se determinó que el tercer round tiene los datos más adecuados para el entrenamiento, además se puede observar que el algoritmo más indicado para la clasificación es DNN con la tercera infraestructura, por lo que se procedió a entrenar este algoritmo y se obtuvo las siguientes métricas de desempeño con el conjunto prueba:

- Accuracy: 80.19%
- Sensibilidad: 79.35 %
- Especificidad: 81.04%

De estos resultados se puede apreciar que el algoritmo es mejor dando como resultado electrocardiogramas con fibrilación auricular, que dando positivos para ritmo sinusal normal como lo muestra la sensibilidad, lo cual es un resultado positivo debido a que en un 81.04 % los pacientes recibirán un tratamiento adecuado que solucione sus problemas cardiacos.

X. CONCLUSIONES.

De este proyecto se puede concluir que la extracción de las características correctas es parte crucial para los resultados del proyecto, pues es la base del éxito del entrenamiento del algoritmo.

Así mismo, es importante definir diferentes tipologías de algoritmos para que, a partir de su comparación con la ayuda de métricas de desempeño, se pueda determinar cuál es la mejor opción para el tipo de datos que se tienen.

La validación cruzada de tipo k-fold ayuda a seleccionar los mejores datos para entrenar el algoritmo y obtener los mejores resultados posibles.

La aplicación de inteligencia artificial en el campo de la medicina y la detección de algunas enfermedades a partir de señales como los electrocardiogramas, tiene un gran potencial en la agilización de algunos procesos en este campo, además de dar la posibilidad al paciente de obtener resultados sin la presencia de un médico o algún encargado de la salud, sin embargo, llevar este tipo de soluciones a poblaciones apartadas en un país como Colombia, debería ser una de las tareas más importantes, pues así sería se sacaría mayor provecho a este tipo de soluciones

XI. TRABAJOS FUTUROS.

Como trabajos futuros, se pretende hacer uso de toda la base de datos para realizar una clasificación multiclase. Adicionalmente hacer uso de algoritmos más complejos como los son la transformada de wavelet para tener una mejor precisión a la hora de detectar ondas P y ondas R y poder extraer una mayor cantidad de información que sea relevante para la clasificación de los ECG.

También, se propone utilizar nuevos algoritmos y estructuras de modelos a la vez de implementar estrategias de Ensemble Learning para obtener un mejor rendimiento a la hora de realizar la clasificación.

XII. REFERENCIAS

- [F. S.-G. 2. , G. C. Giuseppe Lippi 1, «Global epidemiology 1 of atrial fibrillation: An increasing epidemic and public health challenge.,» 07 2017. [En línea]. Available: <https://pubmed.ncbi.nlm.nih.gov/31955707/#:~:text=The%20worldwide%20prevalence%20of%20atrial,middle%20socio%2Ddemographic%20index%20countries..>
- [A. Petrenas, V. Marozas, L. Sörnmo y A. Lukosevicius, 2 «IEEE Xplore,» 10 Octubre 2012. [En línea]. Available: <https://ieeexplore-ieee-org.ezproxy.javeriana.edu.co/search/searchresult.jsp?newsearch=true&queryText=An%20Echo%20State%20Neural%20Network%20for%20QRST%20Cancellation%20During%20Atrial%20Fibrillation.> [Último acceso: 01 Abril 2022].
- [C. Huang, S. Ye, H. Chen, D. Li, F. He y Y. Tu, «IEEE 3 Xplore,» 4 Abril 2011. [En línea]. Available: <https://ieeexplore-ieee-org.ezproxy.javeriana.edu.co/document/5657251.> [Último acceso: 01 Abril 2022].
- [X. Du, N. Rao, M. Qian, D. Liu, J. Li, W. Feng, L. Yin y X. 4 Chen, «A novel method for real-time atrial fibrillation detection in electrocardiograms using multiple parameters,» National Library of Medicine, 2013.
- [H. Pürerfellner, E. Pokushalov, S. Sarkar, J. Koehler, R. 5 Zhou, L. Urban y G. Hindricks, «P-wave evidence as a method for improving algorithm to detect atrial fibrillation in insertable cardiac monitors,» National Library of Medicine, 2014.
- [O. R. Suset Blanco, «Wavelet entropy: A new tool for 6 analysis of short duration brain electrical signals,» Research Gate, 01 2001. [En línea]. Available: https://www.researchgate.net/publication/12164427_Wavelet_entropy_A_new_tool_for_analysis_of_short_duration_brain_electrical_signals. [Último acceso: 04 Marzo 2022].
- [PhysioNet, «AF Classification from a Short Single Lead 7 ECG Recording: The PhysioNet/Computing in Cardiology Challenge 2017 Gari,» 1 6 2017. [En línea]. Available: [https://physionet.org/content/challenge-2017/1.0.0/.](https://physionet.org/content/challenge-2017/1.0.0/) [Último acceso: 24 Marzo 2022].

- [N. Thakor, J. Webster y W. Tompkins, «Optimal QRS
8 detector,» Medical and Biological Engineering and
] Computing, 1983.
- [S. Rao, M. Kolekar y R. Martis, «A Deep Learning Based
9 Assisted Tool for Atrial Fibrillation Detection Using
] Electrocardiogram,» IEEE, Bangalore, 2021.